
LIMITES ACTUELLES

Malgré les avancées significatives des modèles de langage open-source tels que LLaMA, plusieurs limites ont été mises en évidence au cours de ce projet.

Tout d'abord, LLaMA ne prend pas nativement en charge les tools (outils externes). Contrairement aux solutions commerciales modernes, il ne dispose pas d'un mécanisme intégré pour l'appel de fonctions, l'orchestration d'API, la gestion d'outils métier ou l'exécution contrôlée d'actions. Cela complique fortement son intégration dans des systèmes complexes nécessitant une interaction dynamique avec des services externes (bases de données, moteurs de recherche, services vocaux, etc.). En plus du fait que le temps de latence sont longues et certaines modele tel que llama 3 ne prennent pas en charge les tools, elle bloque l'ui si les GPU ne sont pas suffisantes.

Ensuite, les performances sont globalement inférieures aux solutions payantes, en particulier en termes de latence. Les temps de réponse peuvent devenir problématiques dans des applications interactives (chat en temps réel, assistants vocaux), surtout lorsque le modèle est auto-hébergé ou exécuté dans un environnement contraint comme WSL2. Elle ne supporte pas le streaming

Par ailleurs, LLaMA ne supporte pas nativement l'audio (reconnaissance vocale ou synthèse vocale). Toute fonctionnalité liée à la voix nécessite l'ajout de services externes (AssemblyAI, Whisper, TTS tiers), ce qui augmente la complexité de l'architecture, les coûts indirects et les points de défaillance potentiels.

Enfin, les solutions gratuites reposant sur LLaMA exigent de nombreux apports extérieurs : orchestration manuelle, gestion de la mémoire conversationnelle, vectorisation, sécurité, monitoring et mise à l'échelle. Ces responsabilités, généralement prises en charge par les solutions payantes, reposent ici entièrement sur le développeur.

PERSPECTIVES D'ÉVOLUTION

Malgré ces limites, les perspectives restent prometteuses. L'écosystème open-source évolue rapidement, avec l'émergence de frameworks visant à combler les lacunes de LLaMA, notamment en matière de tools, de RAG (Retrieval-Augmented Generation) et d'agents intelligents.

À court terme, une approche hybride apparaît comme la plus pertinente :

- LLaMA pour le raisonnement local et la maîtrise des coûts,
- Des services spécialisés payants ou open-source pour la voix, les tools et l'orchestration

ANALYSE COMPARATIVE DES SOLUTIONS (TABLEAUX)

COMPARATIF DES SOLUTIONS IA CONVERSATIONNELLES

OPENAI (GPT-4, GPT-4O-MINI)

Métrique	GPT-4o-mini	GPT-4 Turbo	GPT-4o
Coût input	\$0.150 / 1M tokens	\$10 / 1M tokens	\$5 / 1M tokens
Coût output	\$0.600 / 1M tokens	\$30 / 1M tokens	\$15 / 1M tokens
Latence	0.5–2 s	1–3 s	0.8–2.5 s
Context window	128k tokens	128k tokens	128k tokens
Support tools	✓ Natif	✓ Natif	✓ Natif
Support audio	✗ (Whisper séparé)	✗	✓ Natif
Streaming	✓ Stable	✓ Stable	✓ Stable
SLA	99.9 %	99.9 %	99.9 %

Coût estimé pour 100 requêtes/jour

Modèle	Type	Coût mensuel approximatif (100 requêtes/jour)
gpt-realtime	Texte	~84 \$/mois
gpt-realtime-mini	Texte	~12,6 \$/mois
gpt-realtime	Audio	~196 \$/mois
gpt-realtime-mini	Audio	~62 \$/mois
gpt-realtime	Image	~7,5 \$/mois
gpt-realtime-mini	Image	~1,2 \$/mois

ANTHROPIC (CLAUDE 3 & 3.5)

Métrique	Claude 3 Haiku	Claude 3.5 Sonnet	Claude 3 Opus
Coût input	\$0.25 / 1M tokens	\$3 / 1M tokens	\$15 / 1M tokens
Coût output	\$1.25 / 1M tokens	\$15 / 1M tokens	\$75 / 1M tokens
Latence	0.4–1.5 s	0.8–2.5 s	1.5–4 s
Context window	200k tokens	200k tokens	200k tokens
Support tools	✓ Très robuste	✓ Très robuste	✓ Très robuste
Streaming	✓ Excellent	✓ Excellent	✓ Excellent

Avantages Claude

- Context window plus large (200k vs 128k)
- Meilleure compréhension de requêtes complexes
- Gestion des tools plus robuste (moins d'erreurs de parsing)
- Réponses généralement plus structurées

GOOGLE (GEMINI)

Métrique	Gemini 1.5 Flash	Gemini 1.5 Pro
Coût input/output	Gratuit (<128k)	\$3.5 / \$10.5
Latence	0.6–2 s	1–3.5 s
Context window	1M tokens	2M tokens
Support tools	✓ Natif	✓ Natif
Support audio	✓ Natif	✓ Natif

Coût estimé pour 1000 requêtes/jour :

- Gemini 1.5 Flash : 0€/mois (<128k tokens)
- Gemini 1.5 Pro : ~326€/mois

Avantages Gemini :

- Context window exceptionnel (jusqu'à 2M tokens)
- Support multimodal natif (texte, image, audio, vidéo)
- Flash gratuit pour usage modéré
- Intégration Google Cloud

AZURE OPENAI

Métrique	Gemini 1.5 Flash	Gemini 1.5 Pro
Coût input/output	Gratuit (<128k)	\$3.5 / \$10.5
Latence	0.6–2 s	1–3.5 s
Context window	1M tokens	2M tokens
Support tools	✓ Natif	✓ Natif
Support audio	✓ Natif	✓ Natif

ASSEMBLYAI

Plan	Gratuit	Standard	Business
Minutes/mois	100	Illimité	Illimité
Coût	0 €	~\$0.022/min	Sur devis
Précision	~95 %	~95 %	~97 %

Avantages :

- API simple et bien documentée
- Webhooks pour traitement asynchrone
- Speaker diarization (identification locuteurs)
- Détection automatique de langue
- PII rédaction (masquage données sensibles)

DEEPGRAM

Plan	Pay-as-you-go	Growth
Coût	\$0.0043/min	\$0.0036/min
Latence streaming	<300 ms	<200 ms
Précision	~96 %	~97 %

Avantages:

- Latence ultra-faible (streaming temps réel)
- Modèles spécialisés par domaine (médical, finance)
- On-premise deployment disponible
- Meilleur rapport performance/prix

Solution / API	Type	≈Coût texte/mois (100 req/j)	≈Coût audio/mois (50h)	Total ≈	Notes clés
OpenAI GPT-4o-mini + Whisper API	Cloud	~1 \$	~10 \$	~11 \$	Économie + précision correcte
OpenAI GPT-4 Turbo + Whisper API	Cloud	~36 \$	~10 \$	~46 \$	Plus performant que mini
Azure GPT-4o-mini + Speech Services	Cloud	~0.9 \$	~50 \$	~51 \$	Conformité entreprise rich features
Azure GPT-4 Turbo + Speech	Cloud	~36.5 \$	~50 \$	~87 \$	Pour charge plus lourde
Anthropic Claude 3 Haiku + Deepgram	Cloud	~23 \$	~20–30 \$	~43–53 \$	Chat robuste + audio rapide
Google Gemini 1.5 Flash + Google Speech	Cloud	~0 \$ (free tokens)	~110 \$	~110 \$	Très bon multimodal mais audio coûteux
Deepgram (seul STT)	Audio	—	~65 \$	~65 \$	Streaming très rapide
AssemblyAI (seul STT)	Audio	—	~330 \$	~330 \$	Coût élevé sur gros volume
Local LLaMA 3.2 + AssemblyAI	Hybride	~0 \$	~20 \$	~20–30 \$	Low cost IA local + cloud audio
Local LLaMA 3.2 + Deepgram	Hybride	~0 \$	~65 \$	~65 \$	Meilleur audio local/stream